

Sadržaj

1	Sustav ANFIS	3
2	Izvod algoritma učenja	5
2.1	Stohastički gradijentni spust	5
2.1.1	Izvod pravila za ažuriranje parametara p , q i r	5
2.1.2	Izvod pravila za ažuriranje parametra a_i	7
2.1.3	Izvod pravila za ažuriranje parametra b_i	8
2.2	Gradijentni spust	9
2.2.1	Izvod pravila za ažuriranje parametara	9
3	Rezultati	10
3.1	Pravilo 1	11
3.2	Pravilo 2	12
3.3	Pravilo 3	13
3.4	Pravilo 4	14

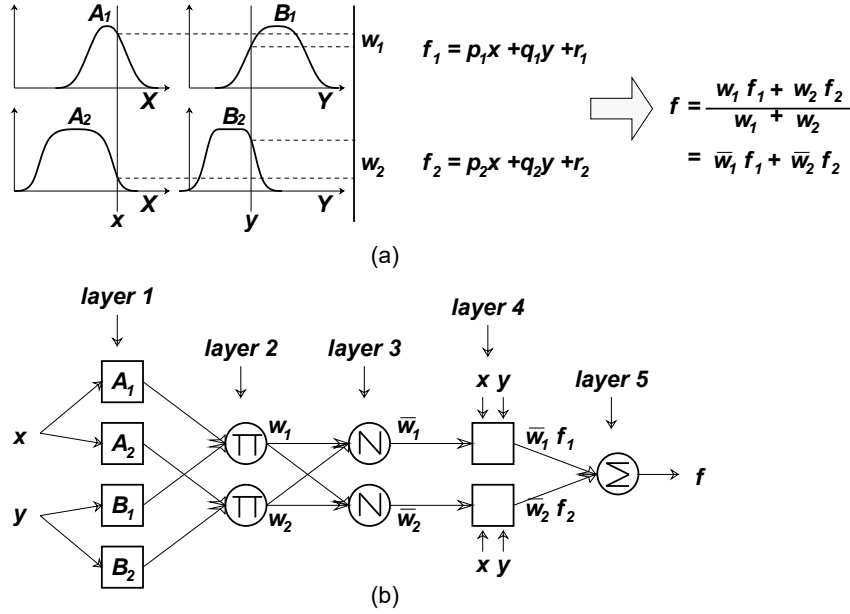
Popis slika

1	ANFIS mreža koja ostvaruje neizraziti sustav (slika preuzeta iz [1])	3
2	Graf prijenosne funkcije sa različitim parametrima	4
3	Prikaz grafa funkcije	10
4	Prikaz grafa funkcije dobivene kao rezultat sustava	11
5	Graf funkcija pripadnosti za pravilo 1	12
6	Prikaz područja na kojemu djeluje pravilo 1	12
7	Prikaz vrijednosti funkcije dobivene pravilom 1	12
8	Graf funkcija pripadnosti za pravilo 2	13
9	Prikaz područja na kojemu djeluje pravilo 2	13
10	Prikaz vrijednosti funkcije dobivene pravilom 2	13
11	Graf funkcija pripadnosti za pravilo 3	14
12	Prikaz područja na kojemu djeluje pravilo 3	14
13	Prikaz vrijednosti funkcije dobivene pravilom 3	14
14	Graf funkcija pripadnosti za pravilo 4	15
15	Prikaz područja na kojemu djeluje pravilo 4	15

16	Prikaz vrijednosti funkcije dobivene pravilom 4	15
----	---	----

1 Sustav ANFIS

Sustav ANFIS (engl. *Adaptive Neuro-Fuzzy Inference System*) koji je objašnjen u [1] hibridni je sustav nastao kombiniranjem neuronskih mreža i sustava neizrazitog zaključivanja. Primjer takvog sustava prikazan je na slici 1.

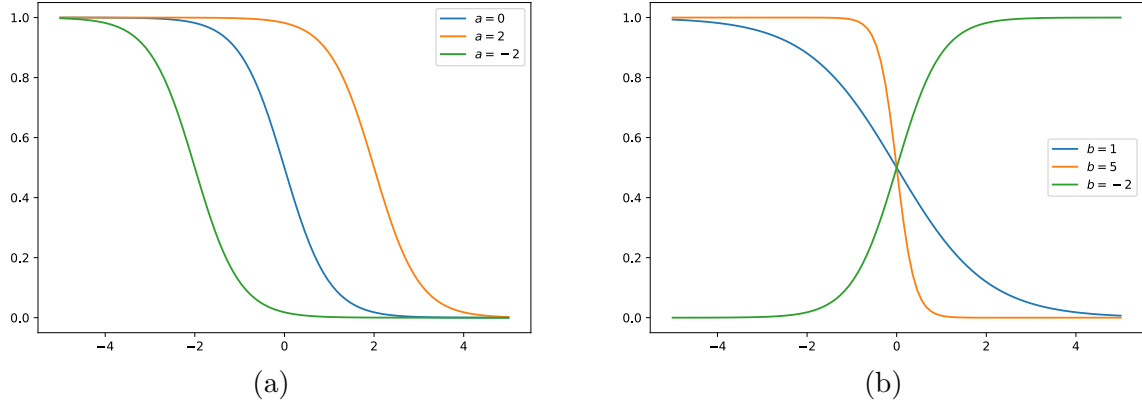


Slika 1: ANFIS mreža koja ostvaruje neizraziti sustav (slika preuzeta iz [1])

Prikazana mreža predstavlja sustav koji ima 2 ulazne varijable x i y te na temelju njih računa rezultat f . Pritom sustav raspolaže sa 2 pravila, što se na slici vidi kao parovi (A_1, B_1) i (A_2, B_2) , odnosno 2 neurona u slojevima 2, 3 i 4. Kako bi se odredile točne vrijednosti brojeva A_i i B_i definira se funkcija pripadnosti, te je u daljnjem radu korištena sigmoidalna funkcija pripadnosti oblika:

$$\mu(x) = \frac{1}{1 + e^{b_i(x-a_i)}}.$$

Korištenjem ove funkcije pripadnosti, svako pravilo ima 2 parametra za svaku ulaznu varijablu, točnije a_i i b_i . Izgled funkcije u ovisnosti o parametrima prikazana je na slici 2. Iz slike 2a može se primjetiti kako parametar a_i zapravo određuje središte sigmoide, odnosno vrijednost x koordinate u kojoj funkcija ima vrijednost 0.5. Promjenom ovog parametra, sigmoide se "pomiče" lijevo ili desno. Na slici 2b prikazano je ponašanje prijenosne funkcije u odnosu na parametar b_i te se može primjetiti kako ovaj parametar određuje



Slika 2: Graf prijenosne funkcije sa različitim parametrima

strminu funkcije. Povećavanjem vrijednosti ovog parametra funkcija postaje strmija, dok se negativnom vrijednosti parametra dobiva zrcalna funkcija.

Vrijednosti neurona u 2. računaju se kao T -norma, te je za potrebe toga korišten algebarski produkt:

$$\mu_{A_i \cap B_i}(x) = \mu_{A_i}(x) \cdot \mu_{B_i}(x).$$

3. sloj koristi se za normalizaciju vrijednosti prethodnog sloja, te se u njemu računa:

$$\bar{w}_i = \frac{w_i}{\sum_{i=1}^n w_i}.$$

U 4. sloju računa se vrijednost funkcije uz trenutno pravilo, za dane ulazne vrijednosti. Korištena je linearna funkcija oblika:

$$f_i = p_i \cdot x + q_i \cdot y + r_i.$$

Vrijednost funkcije se dodatno množi sa w_i iz prethodnog sloja. Primjećuje se da su u ovom sloju dodana 3 nova parametra za svako pravilo, točnije: p_i , q_i i r_i .

U konačnici se u 5. sloju računa konačna vrijednost kao zbroj svih vrijednosti 4. sloja.

2 Izvod algoritma učenja

Neka je dostupno N primjera za učenje oblika (\vec{x}_i, y_i) . Neka je za neki uzorak k izlaz neuronske mreže označen sa o_k , tada se pogreška za taj primjer može definirati kao

$$E_k = \frac{1}{2}(y_k - o_k)^2.$$

Ako parametre ažuriramo u skladu s algoritmom gradijentnog spusta, za ažuriranje nekog proizvoljnog parametra ψ koristi se izraz:

$$\psi(t+1) = \psi(t) - \eta \frac{\partial E_k}{\partial \psi}.$$

2.1 Stohastički gradijentni spust

2.1.1 Izvod pravila za ažuriranje parametara p , q i r

Izlaz sustava definiran je kao težinska suma:

$$o_k = \frac{\sum_{i=1}^m \alpha_i \cdot z_i}{\sum_{i=1}^m \alpha_i},$$

gdje je α_i jakost paljenja i -tog pravila, što je definirano sigmoidalnom funkcijom, odnosno u slučaju ovog konkretnog projekta vrijedi da je:

$$\alpha_i = A_i(x_k^{(1)}) \cdot B_i(x_k^{(2)}).$$

Oznaka z_i jednaka je izračunatoj vrijednosti funkcije za i -to pravilo, odnosno:

$$z_i = p_i \cdot x_k^{(1)} + q_i \cdot x_k^{(2)} + r_i.$$

Potrebno je izračunati parcijalnu derivaciju $\frac{\partial E_k}{\partial z_i}$, za što se koristi pravilo ulančavanja:

$$\frac{\partial E_k}{\partial z_i} = \frac{\partial E_k}{\partial o_k} \cdot \frac{\partial o_k}{\partial z_i}.$$

Svaku od dobivenih parcijalnih derivacija moguće je izračunati zasebno:

$$\begin{aligned}\frac{\partial E_k}{\partial o_k} &= \frac{\partial}{\partial o_k} \left(\frac{1}{2} (y_k - o_k)^2 \right) \\ &= -(y_k - o_k)\end{aligned}$$

$$\begin{aligned}\frac{\partial o_k}{\partial z_i} &= \frac{\partial}{\partial o_k} \left(\frac{\sum_{j=1}^m \alpha_j \cdot z_j}{\sum_{j=1}^m \alpha_j} \right) \\ &= \frac{\alpha_i}{\sum_{j=1}^m \alpha_j}.\end{aligned}$$

Čime se dobije da vrijedi:

$$\frac{\partial E_k}{\partial z_i} = -(y_k - o_k) \frac{\alpha_i}{\sum_{j=1}^m \alpha_j}.$$

Kako je već ranije rečeno da vrijedi da je

$$z_i = p_i \cdot x_k^{(1)} + q_i \cdot x_k^{(2)} + r_i,$$

sad je moguće izračunati parcijalne derivacije po parametrima p_i , q_i i r_i , čime se dobiju sljedeći izrazi:

$$\begin{aligned}\frac{\partial E_k}{\partial p_i} &= \frac{\partial E_k}{\partial z_i} \cdot \frac{\partial z_i}{\partial p_i} \\ &= \frac{\partial E_k}{\partial z_i} \cdot x_k^{(1)} \\ &= -x_k^{(1)} (y_k - o_k) \frac{\alpha_i}{\sum_{j=1}^m \alpha_j},\end{aligned}$$

$$\begin{aligned}\frac{\partial E_k}{\partial q_i} &= \frac{\partial E_k}{\partial z_i} \cdot \frac{\partial z_i}{\partial q_i} \\ &= \frac{\partial E_k}{\partial z_i} \cdot x_k^{(2)} \\ &= -x_k^{(2)} (y_k - o_k) \frac{\alpha_i}{\sum_{j=1}^m \alpha_j},\end{aligned}$$

$$\begin{aligned}\frac{\partial E_k}{\partial r_i} &= \frac{\partial E_k}{\partial z_i} \cdot \frac{\partial z_i}{\partial r_i} \\ &= -(y_k - o_k) \frac{\alpha_i}{\sum_{j=1}^m \alpha_j}.\end{aligned}$$

Iz čega slijede sljedeća pravila za ažuriranje težina:

$$\begin{aligned} p_i(t+1) &= p_i(t) + \eta \cdot x_k^{(1)}(y_k - o_k) \frac{\alpha_i}{\sum_{j=1}^m \alpha_j}, \\ q_i(t+1) &= q_i(t) + \eta \cdot x_k^{(2)}(y_k - o_k) \frac{\alpha_i}{\sum_{j=1}^m \alpha_j}, \\ r_i(t+1) &= r_i(t) + \eta(y_k - o_k) \frac{\alpha_i}{\sum_{j=1}^m \alpha_j}. \end{aligned}$$

2.1.2 Izvod pravila za ažuriranje parametra a_i

Kao i u prethodnom slučaju, potrebno je izračunati parcijalnu derivaciju, što se postiže pravilom ulančavanja:

$$\frac{\partial E_k}{\partial a_i} = \frac{\partial E_k}{\partial o_k} \frac{\partial o_k}{\partial \alpha_i} \frac{\partial \alpha_i}{\partial a_i}.$$

Komponente su tada redom:

$$\begin{aligned} \frac{\partial E_k}{\partial o_k} &= -(y_k - o_k), \\ \frac{\partial o_k}{\partial \alpha_i} &= \frac{\partial}{\partial \alpha_i} \left(\frac{\sum_{j=1}^m \alpha_j \cdot z_j}{\sum_{j=1}^m \alpha_j} \right) \\ &= \frac{z_i \sum_{j=1}^m \alpha_j - \sum_{j=1}^m \alpha_j z_j}{(\sum_{j=1}^m \alpha_j)^2} \\ &= \frac{\sum_{j=1}^m \alpha_j (z_i - z_j)}{(\sum_{j=1}^m \alpha_j)^2}. \end{aligned}$$

Prije računanja treće parcijalne derivacije uvodi se oznaka $\gamma = -b_i(x - a_i)$, tada vrijedi:

$$\begin{aligned}
\frac{\partial \alpha_i}{\partial a_i} &= \frac{\partial \alpha_i}{\partial \gamma} \cdot \frac{\partial \gamma}{\partial a_i}, \\
\frac{\partial \alpha_i}{\partial \gamma} &= \frac{\partial}{\partial \gamma} \left(\frac{1}{1 + e^{-\gamma}} \right) \\
&= \frac{\partial}{\partial \gamma} (1 + e^{-\gamma})^{-1} \\
&= -(1 + e^{-\gamma})^{-2} \cdot (-e^{-\gamma}) \\
&= \frac{e^{-\gamma}}{(1 + e^{-\gamma})^2} \\
&= \frac{1}{1 + e^{-\gamma}} \cdot \frac{e^{-\gamma}}{1 + e^{-\gamma}} \\
&= \frac{1}{1 + e^{-\gamma}} \cdot \left(\frac{1 + e^{-\gamma}}{1 + e^{-\gamma}} - \frac{1}{1 + e^{-\gamma}} \right) \\
&= \frac{1}{1 + e^{-\gamma}} \left(1 - \frac{1}{1 + e^{-\gamma}} \right) \\
&= \alpha_i(1 - \alpha_i), \\
\frac{\partial \gamma}{\partial a_i} &= \frac{\partial}{\partial a_i} (-b_i(x - a_i)) \\
&= \frac{\partial}{\partial a_i} (-b_i x + b_i a_i) \\
&= b_i, \\
\frac{\partial \alpha_i}{\partial a_i} &= b_i \alpha_i (1 - \alpha_i).
\end{aligned}$$

Iz izračunatoga slijedi da se parametar a_i ažurira prema sljedećem pravilu:

$$a_i(t+1) = a_i(t) + \eta(y_k - o_k) \frac{\sum_{j=1}^m \alpha_j(z_i - z_j)}{(\sum_{j=1}^m \alpha_j)^2} b_i \alpha_i (1 - \alpha_i)$$

2.1.3 Izvod pravila za ažuriranje parametra b_i

Kod izvođenja pravila za ažuriranje parametra b_i potrebno je odrediti parcijalnu derivaciju:

$$\frac{\partial E_k}{\partial a_i} = \frac{\partial E_k}{\partial o_k} \frac{\partial o_k}{\partial \alpha_i} \frac{\partial \alpha_i}{\partial \gamma} \frac{\partial \gamma}{\partial b_i}.$$

Od prije su poznate sve parcijalne derivacije osim $\frac{\partial \gamma}{\partial b_i}$, za koju vrijedi:

$$\begin{aligned}\frac{\partial \gamma}{\partial b_i} &= \frac{\partial}{\partial b_i}(-b_i(x - a_i)) \\ &= -(x - a_i).\end{aligned}$$

Iz čega slijedi pravilo za ažuriranje parametra b_i :

$$b_i(t+1) = b_i(t) - \eta(y_k - o_k) \frac{\sum_{j=1}^m \alpha_j(z_i - z_j)}{(\sum_{j=1}^m \alpha_j)^2} (x - a_i) \alpha_i (1 - \alpha_i)$$

2.2 Gradijentni spust

U postupku gradijentnog spusta potrebno je izračunati gradijent za cijeli skup primjera za učenje, zbog čega se greška definira kao:

$$E = \frac{1}{2} \sum_{k=1}^N (y_k - o_k)^2,$$

nakon čega je potrebno sve parcijalne derivacije izračunati u skladu sa ovako definiranom sumom.

2.2.1 Izvod pravila za ažuriranje parametara

Potrebno je izračunati parcijalnu derivaciju $\frac{\partial E}{\partial z_i}$, što je jednako:

$$\begin{aligned}\frac{\partial E}{\partial z_i} &= \frac{\partial}{\partial z_i} \frac{1}{2} \sum_{k=1}^N (y_k - o_k)^2 \\ &= \sum_{k=1}^N \frac{\partial}{\partial z_i} \frac{1}{2} (y_k - o_k)^2,\end{aligned}$$

što je zapravo jednako sumi parcijalnih derivacija iz stohastičkog gradijentnog spusta po svim primjerima. Zbog toga slijedi da je pravilo za ažuriranje parametara:


$$\begin{aligned}
 p_i(t+1) &= p_i(t) + \eta \sum_{k=1}^N x_k^{(1)}(y_k - o_k) \frac{\alpha_i}{\sum_{j=1}^m \alpha_j}, \\
 q_i(t+1) &= q_i(t) + \eta \sum_{k=1}^N x_k^{(2)}(y_k - o_k) \frac{\alpha_i}{\sum_{j=1}^m \alpha_j}, \\
 r_i(t+1) &= r_i(t) + \eta \sum_{k=1}^N (y_k - o_k) \frac{\alpha_i}{\sum_{j=1}^m \alpha_j}, \\
 a_i(t+1) &= a_i(t) + \eta \sum_{k=1}^N (y_k - o_k) \frac{\sum_{j=1}^m \alpha_j (z_i - z_j)}{(\sum_{j=1}^m \alpha_j)^2} b_i \alpha_i (1 - \alpha_i), \\
 b_i(t+1) &= b_i(t) - \eta \sum_{k=1}^N (y_k - o_k) \frac{\sum_{j=1}^m \alpha_j (z_i - z_j)}{(\sum_{j=1}^m \alpha_j)^2} (x - a_i) \alpha_i (1 - \alpha_i).
 \end{aligned}$$

3 Rezultati

Za potrebe ove vježbe treniran je sustav koji aproksimira funkciju:


$$z = ((x - 1)^2 + (y + 2)^2 - 5xy + 3) \cdot \cos\left(\frac{x}{5}\right)^2.$$

Na slici 3 prikazan je graf funkcije koju aproksimiramo. Korištenjem navedene funkcije



Slika 3: Prikaz grafa funkcije

stvoren je skup podataka za učenje na način da su uzorkovani svi cjelobrojni parovi brojeva iz intervala $[-4, 4]$. Tako dobiveni brojevi korišteni su za treniranje sustava. Napravljen je sustav koji koristi 4 pravila te postiže pogrešku u iznosu 0.14. Slika 4 prikazuje graf



Slika 4: Prikaz grafa funkcije dobivene kao rezultat sustava


funkcije koja je dobivena kao rezultat opisanog sustava.

3.1 Pravilo 1


Prvo naučeno pravilo sastoji se od sljedećih težina:

$$[3.3265, -2.4756, -0.2856, -0.1651, -1.3213, 3.6077, 1.3015].$$

Iz slike 11 vidimo grafove funkcije pripadnosti prvog pravila za interval $[-4, 4]$. Iz slike 5a vidimo kako je ovo pravilo specijalizirano za velike vrijednosti x , odnosno mogli bismo reći ” x oko 4”. Iz slike 5b vidimo kako je pravilo malo više specijalizirano za veće vrijednosti y , no svejedno djeluje i na svim vrijednostima iz intervala. Konačno područje na kojemu djeluje ovo pravilo prikazano je slikom 6. Funkcija koja je dobivena ovim pravilom prikazana je na slici 7.



Slika 5: Graf funkcija pripadnosti za pravilo 1



Slika 6: Prikaz područja na kojemu djeluje pravilo 1


Slika 7: Prikaz vrijednosti funkcije dobivene pravilom 1

3.2 Pravilo 2


Drugo naučeno pravilo sastoji se od sljedećih težina:

$$[-3.8725, 1.0394, 5.2885, 3.0510, 1.9408, 1.4077, 4.9346].$$


Iz slike 11 vidimo grafove funkcije pripadnosti drugog pravila za interval $[-4, 4]$. Iz slike 8a vidimo kako je ovo pravilo specijalizirano za manje vrijednosti x , odnosno mogli bismo reći ” x manje od -2 ”. Iz slike 8b vidimo kako ovo pravilo podjednako obuhvaća sve vrijednosti y . Konačno područje na kojemu djeluje ovo pravilo prikazano je slikom 9. Funkcija koja je dobivena ovim pravilom prikazana je na slici 10.



Slika 8: Graf funkcija pripadnosti za pravilo 2



Slika 9: Prikaz područja na kojemu djeluje pravilo 2




Slika 10: Prikaz vrijednosti funkcije dobivene pravilom 2

3.3 Pravilo 3


Treće naučeno pravilo sastoji se od sljedećih težina:

$$[0.7183, -0.6112, -6.6786, -0.9003, 1.9795, -17.0886, 9.7541].$$


Iz slike 11 vidimo grafove funkcije pripadnosti trećeg pravila za interval $[-4, 4]$. Iz slike 11a vidimo kako je ovo pravilo specijalizirano za veće vrijednosti x , odnosno mogli bismo reći ” x veće od 0”. Iz slike 11b vidimo kako je pravilo jednako specijalizirano za sve vrijednosti y . Konačno područje na kojemu djeluje ovo pravilo prikazano je slikom 12. Funkcija koja je dobivena ovim pravilom prikazana je na slici 13.



Slika 11: Graf funkcija pripadnosti za pravilo 3



Slika 12: Prikaz područja na kojemu djeluje pravilo 3




Slika 13: Prikaz vrijednosti funkcije dobivene pravilom 3

3.4 Pravilo 4


Četvrto naučeno pravilo sastoji se od sljedećih težina:

$$[2.5067, 0.6958, 0.0760, -0.2208, -7.3340, 24.5469, 5.7858].$$

Iz slike 14 vidimo grafove funkcije pripadnosti četvrtog pravila za interval $[-4, 4]$. Iz slike 14a vidimo kako je ovo pravilo specijalizirano za manje vrijednosti x , odnosno mogli bismo reći " x je manje od 2". Iz slike 14b vidimo kako je pravilo malo više specijalizirano za veće vrijednosti y , no svejedno djeluje i na svim vrijednostima iz intervala. Konačno područje na kojemu djeluje ovo pravilo prikazano je slikom 15. Funkcija koja je dobivena ovim pravilom prikazana je na slici 16.



Slika 14: Graf funkcija pripadnosti za pravilo 4



Literatura

- [1] Marko Čupić, Bojana Dalbelo Bašić, and Marin Golub. *Neizrazito, evolucijsko i neuroračunarstvo*. 2013.